

# 1 Metodologia chyb

Na vstupe su trajektórie buniek ako 3D tenzory.  $Y$  je požadovaná,  $\hat{Y}$  je predpovedaná sieťou.

**Pre úplnosť poznámka** o tvare a indexovaní tenzorov  $Y$  a  $\hat{Y}$ :

- rozmer tenzora je  $Y[\text{depth}][\text{height}][\text{width}]$ ,
- indexovanie  $Y[k][j][i]$
- index  $k$  určuje bunku,  $k = \langle 0, \text{depth} \rangle$ , v experimente  $k = \langle 0, 38 \rangle$
- index  $j$  určuje časový krok,  $j = \langle 0, \text{height} \rangle$ , v experimente  $j = \langle 0, 9057 \rangle$
- index  $i$  určuje súradnicu polohy,  $i = \langle 0, \text{width} \rangle$ , v experimente  $i = \langle 0, 3 \rangle$

**Najprv sa definuje chyba** ako rozdiel požadovanej a predpovedanej hodnoty

$$E = Y - \hat{Y} \quad (1)$$

**Vypocet relativnej chyby** je nasledovny : v L1 norme pomer chyboveho tenzora  $E$  a prislusnej dlzky tenzora  $Y$ , dostaneme pomocny tenzor  $r_t$ . Tenzor  $\epsilon$  ma nepatrnu kladnu hodnotu a zabranuje deleniu nulou. Nakoniec sa hodnoty spriemeruju a vynasobia 100.

$$r_t = \frac{|E|}{|\hat{Y}| + \epsilon} \quad (2)$$

$$\text{relative\_error} = \bar{r}_t 100\% \quad (3)$$

**Pre modelovanie rozlozenia pravdepodobnosti** chyby, normalnym rozdelenim je potrebne mat priemer chyby a rozptyl. Z pythonu som pouzil hotove funkcie

- $E.\text{mean}()$ , <https://docs.scipy.org/doc/numpy-1.15.0/reference/generated/numpy.mean.html>
- $\text{numpy.std}(E)$ , <https://docs.scipy.org/doc/numpy-1.15.0/reference/generated/numpy.std.html>

$$\text{mean} = E.\text{mean}() \quad (4)$$

$$\text{sigma} = \text{numpy.std}(E) \quad (5)$$

Tu neviem ci to vrati  $\sigma$  alebo  $\sigma^2$ .

**Dalsia vhodna metrika** je root mean square error (RMS). Pocitana ako odmocnina z priemeru druhych mocnin chyb. [https://en.wikipedia.org/wiki/Root\\_mean\\_square](https://en.wikipedia.org/wiki/Root_mean_square) Indexovanie  $\alpha$  je len formalne zjednodusenie - aby sa nemuseli pisat 3 sumy cez  $i, j, k$ . Hodnota  $N$  je potom  $N = \text{width} * \text{height} * \text{depth}$ .

$$\text{rms} = \sqrt{\frac{1}{N} \sum_{\alpha=1}^N E_{\alpha}^2} \quad (6)$$

v pythone ako

```
rms = numpy.sqrt(numpy.mean(numpy.square(error)))
```

**Dalsia vhodna metrika** je absolutna priemerna chyba. Pocitana ako prumer absolutnych hodnot chyby  $E$  v L1 norme.

$$\text{ams} = \frac{1}{N} \sum_{\alpha=1}^N |E_{\alpha}| \quad (7)$$

v pythone ako

```
ams = numpy.mean(numpy.absolute(error))
```

## 2 Spočítané výsledky

Tabuľka uvádza chyby pre siete 0 až 7. Chyby majú priamu interpretáciu ako chyba polohy [um]. Zeleným sú v danej metrike znázornené najlepšie a červeným najhoršie výsledky.

ID	error mean [um]	error sigma [um]	rms [um]	ams [um]	relative_error [%]
0	-8.937	37.229	38.287	14.473	14.681
1	-33.725	205.573	208.321	41.814	42.588
2	-3.513	22.089	22.367	9.055	12.907
3	-0.292	15.36	15.363	6.942	11.321
4	-1.151	10.928	10.988	3.824	7.701
5	-0.224	10.765	10.767	4.248	7.95
6	-0.777	11.711	11.736	4.156	8.428
7	-1.526	11.373	11.474	3.735	7.556

## 3 Je treba

Treba overiť či je to správne. Z každého pohľadu : metodológia, vzorce, interpretácia aj programovanie.

ID	axis X				axis Y				axis Z			
	mean [um]	sigma [um]	rms [um]	rms relative [%]	mean [um]	sigma [um]	rms [um]	rms relative [%]	mean [um]	sigma [um]	rms [um]	rms relative [%]
0	-24.86	61.73	66.55	12.89	-4.47	19.35	19.86	22.09	-0.08	0.08	0.11	46.88
1	-101.11	357.29	371.32	71.9	-9.06	69.57	70.16	78.04	-0.81	2.85	2.96	1239.89
2	-3.29	36.79	36.93	7.15	-8.17	14.67	16.79	18.68	-0.11	0.13	0.17	69.61
3	4.29	25.07	25.44	4.93	-5.15	10.16	11.39	12.67	-0.11	0.08	0.14	56.87
4	-0.05	19.16	19.16	3.71	-3.54	4.21	5.5	6.12	-0.2	0.19	0.27	114.96
5	2.48	18.54	18.71	3.62	-3.06	4.7	5.61	6.24	-0.16	0.19	0.24	101.16
6	0.48	20.63	20.64	4.0	-2.75	4.44	5.22	5.81	-0.29	0.24	0.37	156.44
7	-1.44	19.9	19.96	3.86	-3.42	4.83	5.91	6.58	-0.17	0.16	0.23	96.09

ID	total error			
	mean [um]	sigma [um]	rms [um]	rms relative [%]
0	-9.8	38.88	40.1	7.23
1	-36.99	215.02	218.18	39.32
2	-3.85	23.11	23.43	4.22
3	-0.32	16.09	16.09	2.9
4	-1.26	11.44	11.51	2.07
5	-0.25	11.27	11.28	2.03
6	-0.85	12.26	12.29	2.22
7	-1.67	11.9	12.02	2.17